PENGENALAN POLA AKSARA JAWA

Disusun Oleh Kelompok 11 :

1. Rafif Huda Aditya 32602100109
2. Reysita Nazela Fitrah 32602100110
3. Rika Amelia 32602100111
4. Tubagus Alwasi'I 32602100112

PRODI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS ISLAM SULTAN AGUNG
SEMARANG

2024

A. Perencanaan

1. Pengambilan Data
   Langkah pertama, mencari dataset aksara jawa di Kaggle dan unduh data tersebut pastikan dataset memiliki label yang sesuai dengan huruf aksara jawa yang terkandung. Format data berupa gambar (JPEG,PNG) aksara jawa. Kami mengambil dataset di Kaggel dan berikut link dataset :
   https://www.kaggle.com/datasets/vzrenggamani/hanacaraka
2. Preprocessing Data
   a. Resizing
      Mengubah ukuran gambar ke dimensi yang diinginkan.
   b. Grayscale Conversion
      Mengonversikan gambar dari yang berwarna menjadi skala abu abu.
   c. Load data
      Memuat dataset ke dalam bahasa pemprograman Python.
3. Model
   Menggunakan model Convolutional Neural Networks (CNN) untuk melatih model pada fitur yang diekstraksi.
4. Flowchart

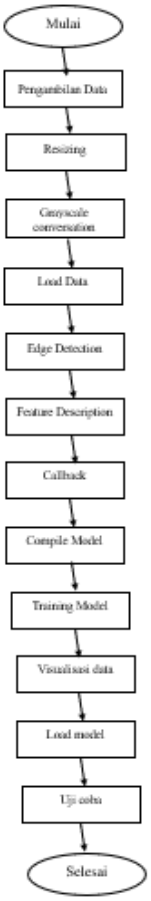

B. Membaca Data dan Preprocessing

Berikut merupakan proses untuk membaca data dan melakukkan preprocessing :

1. Ekstrak dataset
   Dataset hanacaraka terdiri dari 20 folder yaitu ha, na, ca, ra, ka, da, ta, sa, wa, la, pa, dha, ja, ya, nya, ma, ga, ba, tha, dan nga yang masing-masing folder terdiri dari 510 gambar. Total gambar secara keseluruhan pada dataset adalah 10.200 gambar
   Menghubungkan google colab dan google drive

```
from google.colab import drive

drive.mount("/content/gdrive/")
```

   Mengekstrak dataset

```
import zipfile

filename = "/content/gdrive/My Drive/dataset.zip"
zip_ref = zipfile.ZipFile(filename)
zip_ref.extractall()
zip_ref.close()
```

2. Pembagian Set Pelatihan: Membagi dataset menjadi set pelatihan dan validasi. Kemudian setiap folder karakter aksara jawa akan dibagi menjadi 2 bagian, yaitu train dan validation dengan proporsi masing-masing 80% dan 20%.

```
└── hanacaraka
    ├── train
    │   ├── ha ( 80% )
    │   ├── na ( 80%)
    │   ├── ...
    │   └── nga ( 80% )
    ├── val
    │   ├── ha ( 20% )
    │   ├── na ( 20%)
    │   ├── ...
    │   └── nga ( 20% )
    ├── ha ( 510 gambar )
    ├── na ( 510 gambar )
    ├── ...
    └── nga ( 510 gambar )
```

3. Pada bagian ini adalah Memproses data sebelum di load menggunakan ImageDataGenerator(). ImageDataGenerator() dapat melakukan preprocessing, pelabelan sampel otomatis, dan augmentasi gambar.

Kemudian load data ke dalam memori dengan fungsi flow_from_directory().

```
import os
import shutil
from sklearn.model_selection import train_test_split

# Membuat direktori train dan validation
base_dir = "/content/hanacaraka"
train_dir = os.path.join(base_dir, "train")
val_dir = os.path.join(base_dir, "val")

os.mkdir(train_dir)
os.mkdir(val_dir)

# Inisialisasi 20 folder karekter aksara jawa
ha_dir = os.path.join(base_dir, "ha")
na_dir = os.path.join(base_dir, "na")
ca_dir = os.path.join(base_dir, "ca")
ra_dir = os.path.join(base_dir, "ra")
ka_dir = os.path.join(base_dir, "ka")
da_dir = os.path.join(base_dir, "da")
ta_dir = os.path.join(base_dir, "ta")
sa_dir = os.path.join(base_dir, "sa")
wa_dir = os.path.join(base_dir, "wa")
la_dir = os.path.join(base_dir, "la")
pa_dir = os.path.join(base_dir, "pa")
dha_dir = os.path.join(base_dir, "dha")
ja_dir = os.path.join(base_dir, "ja")
ya_dir = os.path.join(base_dir, "ya")
nya_dir = os.path.join(base_dir, "nya")
ma_dir = os.path.join(base_dir, "ma")
ga_dir = os.path.join(base_dir, "ga")
ba_dir = os.path.join(base_dir, "ba")
tha_dir = os.path.join(base_dir, "tha")
nga_dir = os.path.join(base_dir, "nga")
```

4. Menampilkan kelas-kelas pada dataset. Urutan kelas ini nantinya akan dijadikan acuan dalam membuat array classes yang digunakan dalam proses uji coba.

```
from tensorflow.keras.preprocessing.image import ImageDataGenerator

train_datagen = ImageDataGenerator(
    rescale = 1./255,
    rotation_range = 20,
    shear_range = 0.2,
    zoom_range = 0.2,
    fill_mode = "nearest"
)

validation_datagen = ImageDataGenerator(
    rescale = 1./255,
    rotation_range = 20,
    shear_range = 0.2,
    zoom_range = 0.2,
    fill_mode = "nearest"
)

train_generator = train_datagen.flow_from_directory(
    train_dir,
    target_size = (100, 100),
    batch_size = 32,
    class_mode = "categorical",    # Gunakan categorical untuk klasifikasi 3 kelas atau lebih,
    color_mode = "grayscale"       # untuk klasifikasi dua kelas gunakan binary
)

validation_generator = validation_datagen.flow_from_directory(
    val_dir,
    target_size = (100, 100),
    batch_size = 32,
    class_mode = "categorical",    # Gunakan categorical untuk klasifikasi 3 kelas atau lebih
    color_mode = "grayscale"       # untuk klasifikasi dua kelas gunakan binary
)
```

```
Found 8160 images belonging to 20 classes.
Found 2040 images belonging to 20 classes.
```

5. Menampilkan mapping atau peta dari nama kelas Hanacaraka

```
print(train_generator.class_indices)
```

```
{'ba': 0, 'ca': 1, 'da': 2, 'dha': 3, 'ga': 4, 'ha': 5, 'ja': 6, 'ka': 7, 'la': 8, 'ma': 9, 'na': 10, 'nga':
11, 'nya': 12, 'pa': 13, 'ra': 14, 'sa': 15, 'ta': 16, 'tha': 17, 'wa': 18, 'ya': 19}
```

C. Penggunaan Metode, Training dan Testing

1. Penggunaan Metode
   a. CNN

      Menggunakan metode Convolutional Neural Networks (CNN) untuk melatih model pada fitur yang diekstraksi.

   b. Membuat Arsitektur Model CNN

```
import tensorflow as tf

model = tf.keras.models.Sequential([
    tf.keras.layers.Conv2D(32, (3, 3), padding = "same", activation = "relu", input_shape = (100, 100, 1)),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.Conv2D(64, (3, 3), padding = "same", activation = "relu"),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.Conv2D(128, (3, 3), padding = "same", activation = "relu"),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.Conv2D(128, (3, 3), padding = "same", activation = "relu"),
    tf.keras.layers.MaxPooling2D(2, 2),
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dropout(0.5),                       # Untuk menghindari terjadinya overfitting
    tf.keras.layers.Dense(512, activation = "relu"),
    tf.keras.layers.Dense(20, activation = "softmax")   # Gunakan softmax untuk klasifikasi 3 kelas atau lebih,
])                                                      # untuk klasifikasi dua kelas gunakan sigmoid

model.summary()
```

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 conv2d (Conv2D)             (None, 100, 100, 32)      320

 max_pooling2d (MaxPooling2  (None, 50, 50, 32)        0
 D)

 conv2d_1 (Conv2D)           (None, 50, 50, 64)        18496

 max_pooling2d_1 (MaxPoolin  (None, 25, 25, 64)        0
 g2D)

 conv2d_2 (Conv2D)           (None, 25, 25, 128)       73856

 max_pooling2d_2 (MaxPoolin  (None, 12, 12, 128)       0
 g2D)

 conv2d_3 (Conv2D)           (None, 12, 12, 128)       147584

 max_pooling2d_3 (MaxPoolin  (None, 6, 6, 128)         0
 g2D)

 flatten (Flatten)           (None, 4608)              0

 dropout (Dropout)           (None, 4608)              0

 dense (Dense)               (None, 512)               2359808

 dense_1 (Dense)             (None, 20)                10260

=================================================================
Total params: 2610324 (9.96 MB)
Trainable params: 2610324 (9.96 MB)
Non-trainable params: 0 (0.00 Byte)
_________________________________________________________________
```

Keterangan :

- Pada Convolutional layer pertama setiap satu input gambar akan menghasilkan 32 gambar baru dengan ukuran (100 x 100). Kemudian, resolusi tiap gambar akan diperkecil dengan tetap mempertahankan informasi pada gambar menggunakan MaxPoling layer yang berukuran (2, 2) dan menghasilkan ukuran output gambar sebesar (50 x 50). Proses ini juga berlaku untuk Convolutional dan MaxPoling layer.
- Output dari MaxPoling layer terakhir yang terdiri dari 128 gambar dengan ukuran (6, 6) akan diubah ke dalam bentuk array 1D (tensor 1D) dan menghasilkan output berukuran (

4608). Lalu Menggunakan Dropout (0.5) untuk mengurangi overfitting.

- Output tersebut kemudian masuk ke dalam Dense layer pertama yang memiliki 512 neuron dan menghasilkan output dengan ukuran (512).
- Output dari Dense layer pertama akan diteruskan menuju Dense layer kedua yang memiliki 20 neuron sehingga akan menghasilkan output dengan ukuran (20).

c. Compile model

Menentukan loss function, optimizer, dan metrics yang akan digunakan.

```
model.compile(                          # Gunakan categorical_crossentropy untuk klasifikasi 3 kelas atau lebih,
    loss = "categorical_crossentropy",  # untuk klasifikasi dua kelas gunakan binary_crossentropy
    optimizer = tf.optimizers.Adam(
        learning_rate = 0.0003          # Learning rate 0.0003 ( default = 0.001 ) untuk menghindari terjadinya overf
    ),
    metrics = ["accuracy"]
)
```

d. Membuat Callback

```
from keras.callbacks import ModelCheckpoint, EarlyStopping

checkpoint = ModelCheckpoint("model.h5", monitor = "val_accuracy", mode = "auto", save_best_only = True, verbose = 1)
earlystop = EarlyStopping(monitor = "val_accuracy", min_delta = 0, patience = 10, verbose = 1, restore_best_weights = T
```

- ModelCheckPoint() digunakan untuk menyimpan model setelah setiap epoch.
- EarlyStopping() digunakan untuk menghentikan proses training lebih awal.

2. Training Model

a. Mnggunakan fungsi fit().

```
STEP_PER_EPOCH = train_generator.n // train_generator.batch_size
VALIDATION_STEPS = validation_generator.n // validation_generator.batch_size

history = model.fit(
    train_generator,
    steps_per_epoch = STEP_PER_EPOCH,
    epochs = 100,
    validation_data = validation_generator,
    validation_steps = VALIDATION_STEPS,
    verbose = 1,
    callbacks = [checkpoint, earlystop]
)
```

Hasil :

```
Epoch 80/100
255/255 [==============================] - ETA: 0s - loss: 0.0480 - accuracy: 0.9847
Epoch 80: val_accuracy did not improve from 0.97272
255/255 [==============================] - 231s 905ms/step - loss: 0.0480 - accuracy: 0.9847 - val_loss: 0.1392 - val_acc
uracy: 0.9673
Epoch 81/100
255/255 [==============================] - ETA: 0s - loss: 0.0456 - accuracy: 0.9860
Epoch 81: val_accuracy did not improve from 0.97272
255/255 [==============================] - 231s 905ms/step - loss: 0.0456 - accuracy: 0.9860 - val_loss: 0.1295 - val_acc
uracy: 0.9683
Epoch 82/100
255/255 [==============================] - ETA: 0s - loss: 0.0436 - accuracy: 0.9841
Epoch 82: val_accuracy did not improve from 0.97272
255/255 [==============================] - 234s 918ms/step - loss: 0.0436 - accuracy: 0.9841 - val_loss: 0.1370 - val_acc
uracy: 0.9663
Epoch 83/100
255/255 [==============================] - ETA: 0s - loss: 0.0500 - accuracy: 0.9826
Epoch 83: val_accuracy did not improve from 0.97272
255/255 [==============================] - 234s 917ms/step - loss: 0.0500 - accuracy: 0.9826 - val_loss: 0.1481 - val_acc
uracy: 0.9643
Epoch 84/100
255/255 [==============================] - ETA: 0s - loss: 0.0479 - accuracy: 0.9831
Epoch 84: val_accuracy did not improve from 0.97272
255/255 [==============================] - 264s 1s/step - loss: 0.0479 - accuracy: 0.9831 - val_loss: 0.1328 - val_accura
cy: 0.9643
Epoch 85/100
255/255 [==============================] - ETA: 0s - loss: 0.0511 - accuracy: 0.9827
Epoch 85: val_accuracy did not improve from 0.97272
255/255 [==============================] - 268s 1s/step - loss: 0.0511 - accuracy: 0.9827 - val_loss: 0.1319 - val_accura
cy: 0.9680
Epoch 86/100
255/255 [==============================] - ETA: 0s - loss: 0.0377 - accuracy: 0.9871
Epoch 86: val_accuracy did not improve from 0.97272
Restoring model weights from the end of the best epoch: 76.
255/255 [==============================] - 259s 1s/step - loss: 0.0377 - accuracy: 0.9871 - val_loss: 0.1383 - val_accura
cy: 0.9673
Epoch 86: early stopping
```

Pada proses training, estimasi waktu yang dibutuhkan dalam satu epoch berkisar antara 4 – 5 menit. Hal ini dikarenakan proses training yang berjalan menggunakan GPU dari Google Colab.

b. Visualisasi Data

Membuat visualisasi data untuk menampilkan history model accuracy dan model loss selama proses training berlangsung.

```
import matplotlib.pyplot as plt

acc = history.history["accuracy"]
val_acc = history.history["val_accuracy"]

loss = history.history["loss"]
val_loss = history.history["val_loss"]

plt.style.use("seaborn")
fig, ax = plt.subplots(nrows = 1, ncols = 2, figsize = (15, 5))

ax[0].plot(acc, label = "Training Accuracy")
ax[0].plot(val_acc, label = "Validation Accuracy")
ax[0].legend(loc = "lower right")
ax[0].set_title("Model Accuracy", fontsize = 16)
ax[0].set_xlabel("Epoch")
ax[0].set_ylabel("Accuracy")

ax[1].plot(loss, label = "Training Loss")
ax[1].plot(val_loss, label = "Validation Loss")
ax[1].legend(loc = "upper right")
ax[1].set_title("Model Loss", fontsize = 16)
ax[1].set_xlabel("Epoch")
ax[1].set_ylabel("Loss")

plt.show()
```

Kode ini digunakan untuk memvisualisasikan performa model selama pelatihan menggunakan matplotlib. Grafik yang dihasilkan menunjukkan akurasi dan loss untuk data pelatihan dan validasi pada setiap epoch. Dengan memplot ini, kita dapat memantau bagaimana model belajar dari waktu ke waktu dan mendeteksi masalah seperti overfitting.

Hasil grafik :

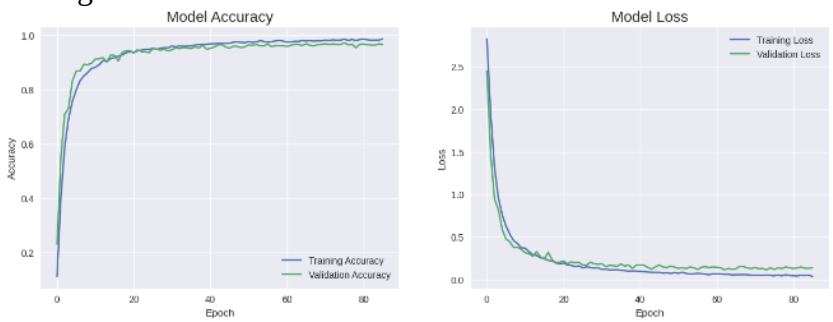

c. Menyalin Model

Menyalin model terbaik yang telah disimpan dengan callback selama proses training berlangsung ke dalam Google Drive.

```
!cp /content/model.h5 "/content/gdrive/My Drive/Hanacaraka"
```

d. Load Model

Setelah model disimpan pada Google Drive, model tersebut akan didownload dan diload untuk uji coba.

```
from keras.models import load_model

load_model = load_model("/content/model.h5")
```

3. Uji Coba
   a. Uji Coba Menggunakan Gambar

      Data yang digunakan untuk uji coba ini adalah data baru yang tidak terlibat sama sekali dalam proses training.

```
import os
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
from keras.preprocessing import image

classes = [
    "ba", "ca", "da", "dha", "ga", "ha", "ja", "ka", "la", "ma",
    "na", "nga", "nya", "pa", "ra", "sa", "ta", "tha", "wa", "ya"
]

path = "/content/gdrive/MyDrive/prediction"
fig, ax = plt.subplots(nrows = 4, ncols = 5, figsize = (20, 20))
# Muat model dengan nama variabel yang berbeda untuk menghindari penimpaan fungsi
model = load_model("/content/model.h5")

x = 0
for y, img_name in enumerate(os.listdir(path)):
    img_path = "{}{}{}".format(path, "/", img_name)
    img = image.load_img(img_path, color_mode = "grayscale", target_size = (100, 100))

    img = image.img_to_array(img)
    img = np.expand_dims(img, axis = 0)

     # Gunakan variabel 'model' untuk prediksi
    result = model.predict(img)

    img_preview = mpimg.imread(img_path)

    if (y > 1) and (y % 5 == 0):
        x += 1

    ax[x, (y % 5)].set_title("{} / prediction: {}".format(img_name, classes[np.argmax(result)]))
    ax[x, (y % 5)].imshow(img_preview)
```

      Hasil :

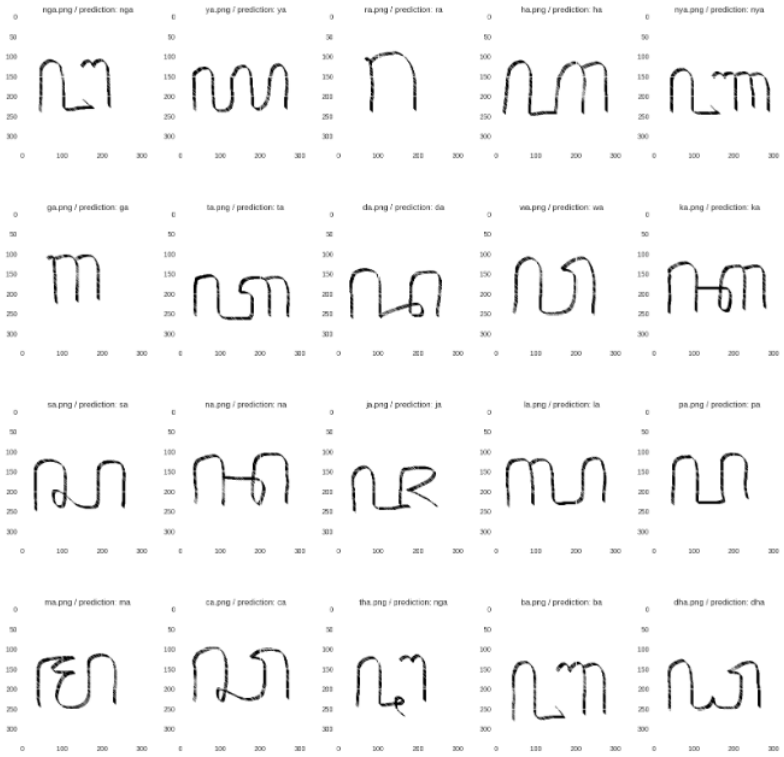

b. Uji Coba Menggunakan Digital Handwriting

Data yang digunakan untuk uji coba ini adalah gambar digital handwriting hanacaraka.

```
import numpy as np
import matplotlib.pyplot as plt
from PIL import Image
from keras.models import load_model
from keras.preprocessing import image

# Load model Keras (pastikan model telah disimpan di path yang sesuai)
model = load_model('/content/model.h5')

# Fungsi untuk memprediksi kelas dari gambar
def classify_image(img_path):
    classes = [
        "ba", "ca", "da", "dha", "ga", "ha", "ja", "ka", "la", "ma",
        "na", "nga", "nya", "pa", "ra", "sa", "ta", "tha", "wa", "ya"
    ]

    img = image.load_img(img_path, color_mode="grayscale", target_size=(100, 100))
    img_array = image.img_to_array(img)
    img_array = np.expand_dims(img_array, axis=0)

    prediction = model.predict(img_array)
    predicted_class = classes[np.argmax(prediction)]

    return predicted_class, img

# Contoh penggunaan
img_path = '/content/gdrive/MyDrive/images/temp.png'
predicted_class, img = classify_image(img_path)
print(f"Result: {predicted_class}")


# Menampilkan gambar
plt.imshow(img, cmap='gray')
plt.title(f"Predicted: {predicted_class}")
plt.axis('off')
plt.show()
```

Hasil :

```
1/1 [==============================] - 0s 133ms/step
Result: ha
```